

Programmation Python

UIE : IA2

Solemane COULIBALY (solemane.coulibaly@gmail.com)

22 janvier 2026

FICHE DE PROBLÈME

Contexte et objectif

Contexte :

Dans de nombreux pays, les secteurs éducatif, sanitaire et économique produisent aujourd'hui de grandes quantités de données. L'analyse de ces données permet d'améliorer la **prise de décision**, l'optimisation des ressources et la **prévision des risques**. Vous avez été recruté comme *Data Analyst junior* par une agence immobilière nationale. L'agence dispose d'un jeu de données brut concernant les transactions immobilières de l'année passée, mais ces données sont "sales" et inexploitées.

Objectif :

Votre mission est de nettoyer, explorer et visualiser ces données afin de fournir un rapport d'aide à la décision pour la direction puis à proposer une **modélisation prédictive simple** afin d'aider les décideurs.. Vous devez identifier les régions les plus dynamiques, l'impact de la surface sur le prix, et l'évolution temporelle des ventes.

Objectif Pédagogique : L'accent est mis sur la **qualité des données**. Un modèle de Machine Learning, aussi puissant soit-il, ne donnera rien de bon si les données en entrée sont mauvaises (*Garbage In, Garbage Out*).

Répartition de l'effort :

- **Partie 1, 2, 3 (90%) :** Exploration, Nettoyage, Visualisation, Encodage.
- **Partie 4 (10%) :** Premier modèle de régression avec Scikit-Learn.

Livrables attendus :

1. Le Jupyter Notebook bien commenté contenant tout le code.
2. Un court rapport résumant votre travail.
3. Le jeu de données nettoyé

Structure du Jeu de Données (`housing_predict.csv`)

Le fichier contient 5 000 transactions passées :

- `id_maison` : Identifiant unique.
- `quartier` : Secteur de la ville ('Centre', 'Sud', 'Nord', 'Ouest').
- `surface_m2` : Surface habitable.
- `nb_chambres` : Nombre de chambres.

- `annee_construction` : Année de construction du bien.
- `etat_general` : Note de l'agent sur 10 (parfois manquante).
- `proche_ecole` : Booléen (0 ou 1).
- `prix_vente` : La cible à prédire (Target).

Partie 1 : Préparation et Nettoyage des Données (pandas & numpy)

1. Chargement et inspection

- Importez les bibliothèques nécessaires (`numpy`, `pandas`, `matplotlib.pyplot`) et chargez le fichier CSV.
- Affichez les 5 premières lignes, le type des colonnes et les statistiques descriptives de base.

2. Traitement des manquants (missing values) :

- Identifiez le pourcentage de valeurs manquantes par colonne.
- Pour la colonne `surface_m2`, remplacez les valeurs manquantes par la **médiane** des surfaces calculée par `type_bien`.
- Pour `etat_general` : Remplacez les manquants par la valeur **5** (état moyen par défaut).
- Supprimez les lignes où le `prix_vente` est manquant.

3. Nettoyage des incohérences :

- Supprimez les transactions où la `surface_m2` est inférieure ou égale à 9 m2 (considéré comme erreur de saisie ou non habitable).
- Vérifiez s'il y a des doublons dans `id_transaction` et supprimez-les.

- 4. **Conversion** : Assurez-vous que la colonne `date_transaction` est bien au format `datetime`. Créez une nouvelle colonne `mois_transaction` contenant le mois de la vente.

5. Détection d'anomalies (Outliers) :

- Certaines `annee_construction` sont aberrantes (ex: 2050 ou 200). Filtrez pour ne garder que les années entre 1900 et l'année actuelle.
- Identifiez et supprimez les biens dont le `prix_vente` est anormalement bas (ex : < 10 000, erreur de saisie probable).

Partie 2 : Feature engineering (création de variables)

Le but est de créer des variables plus pertinentes pour le futur modèle.

1. Âge du bien :

- Créez une colonne `age_bien` = Année Actuelle - `annee_construction`.
- Supprimez ensuite la colonne `annee_construction` (redondante).

2. Catégorisation de la surface :

- Créez une colonne `classe_surface` :
- "Petit" si `surface` < 50
- "Moyen" si `50 <= surface < 100`
- "Grand" si `surface >= 100`

- 3. **Prix au m2** : Créez une colonne `prix_m2` calculée comme :

$$\frac{\text{prix_vente}}{\text{surface_m2}}$$

4. Agrégation par Ville :

- Calculez le prix moyen au m^2 pour chaque ville.
- Classez les villes de la plus chère à la moins chère.

Partie 3 : Analyse exploratoire visuelle (matplotlib/seaborn)

1. Matrice de Corrélation :

- Affichez la Heatmap des corrélations entre toutes les variables numériques.
- Afficher la matrice de corrélation entre `surface_m2`, `nb_pieces` et `prix_vente`. Commentez le résultat.

2. Filtrage complexe : Sélectionnez uniquement les maisons ayant plus de 4 pièces et vendues à un prix inférieur à la moyenne nationale des maisons. Combien y en a-t-il ?

3. Relation Prix / Quartier :

- Utilisez un `boxplot` pour visualiser la distribution des prix par quartier.
- Quel quartier semble le plus cher ? Y a-t-il beaucoup de disparités ?

4. Scatter Plot Multivarié :

- Tracez `surface_m2` (X) vs `prix_vente` (Y).
- Colorez les points selon la note `etat_general`. Interprétez graphiquement l'impact de l'état du bien sur le prix à surface égale.

Partie 4 : Initiation au Machine Learning (scikit-learn)

On ne demande pas d'optimiser le modèle, juste de le faire tourner.

1. Préparation des données (split) :

- Séparez vos données en **X** (toutes les colonnes sauf le prix) et **y** (le `prix_vente`).
- Utilisez `train_test_split` de `sklearn.model_selection` pour diviser les données : 80% pour l'entraînement (Train), 20% pour le test (Test).

2. Entraînement :

- Importez `LinearRegression` (et deux autres modèles choisis) de `sklearn.linear_model`.
- Instanciez le modèle et entraînez-le sur les données d'entraînement.

3. Évaluation simple :

- Calculez le **score R^2** sur les données de test. (Expliquez en une phrase ce que ce score signifie).
- **Comparaison réelle** : Affichez côte à côte les 5 premières prédictions du modèle et les 5 vrais prix correspondants dans le jeu de test.

Barème indicatif (sur 20) :

Ce barème reflète la répartition 90/10.

- **Nettoyage des données (Partie 1) : 5 pts.**

- **Feature Engineering & Encodage (Partie 2) : 5 pts.**
- **Visualisation et Analyse (Partie 3) : 5 pts .**
- **Modélisation ML (Partie 4) : 3 pts.**
- **Qualité du code et commentaires : 2 pts.**

Plan conseillé du rapport

Page de garde :

- Titre : *Analyse des données immobilières*
- Nom(s) de l'étudiant
- Classe / Niveau
- Date de soumission (ne mettez pas une date à laquelle le document n'a pas été soumis)
- Année universitaire

Résumé

Ce travail consiste à analyser un jeu de données réel à l'aide des bibliothèques Python dédiées à la Data Science. L'objectif est d'explorer, nettoyer, analyser et visualiser les données afin d'en extraire des informations utiles, puis d'introduire un modèle simple de machine learning pour la prédiction.

Table des matières

1. Introduction

1.1 Contexte

Présenter brièvement le domaine du dataset

Expliquer **l'intérêt de l'analyse de données** dans ce contexte.

1.2 Objectifs du travail

- Analyser un jeu de données réel
- Extraire des indicateurs pertinents
- Visualiser les résultats
- Tester un modèle simple d'IA

2. Présentation du jeu de données

2.1 Description générale

- Source du dataset
- Nombre d'observations
- Nombre de variables

2.2 Description des variables

Présenter un tableau :

Variable	Type	Description
age	Numérique	Âge de l'individu
sexe	Catégorielle	Sexe (M/F)
...	...	...

3. Prétraitement et nettoyage des données

3.1 Chargement des données

Expliquer brièvement comment les données ont été importées.

3.2 Problèmes rencontrés

- Valeurs manquantes
- Valeurs aberrantes
- Incohérences

3.3 Méthodes de nettoyage

- Suppression
- Remplacement
- Justification des choix

4. Analyse descriptive et exploratoire

- Statistiques descriptives
- Analyse par groupes

Analyse des relations

- etc

5. Visualisation des données

- Inclure et expliquer mes graphiques
- Pour chaque graphique :
 - Titre
 - Axes nommés
 - Interprétation en texte

6. Introduction au Machine Learning

6.1 Objectif de la modélisation

Expliquer ce que l'on cherche à prédire.

6.2 Données utilisées

- Variables explicatives
- Variable cible

6.3 Modèles utilisés

- Régression linéaire **ou**
- Régression logistique

6.4 Résultats

- Accuracy ou erreur
- Interprétation simple

7. Conclusion

- Récapitulatif du travail réalisé (résumé des principaux résultats)
- Apports du projet